

5 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos adotados na construção e na avaliação do protótipo de Epidemiologia Digital desenvolvido neste trabalho. São detalhados a caracterização da pesquisa, as ferramentas empregadas, a delimitação e a coleta do corpus, a estruturação e a persistência dos dados, o pipeline de Processamento de Linguagem Natural (PLN) para o Reconhecimento de Entidades Nomeadas (NER), a heurística de associação entre entidades, a construção do conjunto de referência (Padrão-Ouro) e o procedimento de avaliação quantitativa. Em relação ao previsto no projeto de pesquisa, registram-se ajustes metodológicos motivados por requisitos de reprodutibilidade e viabilidade, justificados ao longo do texto.

5.1 CARACTERIZAÇÃO DA PESQUISA

Quanto à natureza, a pesquisa classifica-se como aplicada, por produzir um artefato tecnológico — um protótipo de software concebido como instrumento de investigação — voltado a um problema prático de vigilância em saúde. Quanto aos objetivos, é exploratória, ao investigar a aplicação de técnicas de PLN ao contexto específico do Piauí, e descritiva, ao registrar e analisar as etapas de desenvolvimento e o desempenho do sistema. Quanto à abordagem, é mista (quali-quantitativa): qualitativa na interpretação semântica dos textos e na análise dos erros de extração, e quantitativa na mensuração estatística do desempenho do modelo e na agregação das menções extraídas.

Cabe destacar que o produto resultante é tratado como instrumento metodológico de investigação, e não como sistema de vigilância em produção. O protótipo não substitui os sistemas oficiais de vigilância epidemiológica, não realiza diagnóstico e não deve constituir fonte única para decisões em saúde pública.

5.2 MATERIAIS E FERRAMENTAS

O desenvolvimento utilizou a linguagem Python (versão 3.11) e bibliotecas de código aberto. O reconhecimento de entidades apoiou-se na biblioteca spaCy, com o modelo *pt_core_news_lg* e mecanismo de contingência para os modelos *md*, *sm* e, em última instância, um pipeline em branco com segmentador de sentenças. A coleta

e a análise de páginas empregaram as bibliotecas *requests*, *BeautifulSoup* e *lxml*; a persistência foi feita em *SQLite* (módulo *sqlite3*); a manipulação tabular, com *pandas*; e a interface de visualização, com *Streamlit*, integrado ao *Folium* e ao *Plotly*. A suíte de testes automatizados foi escrita com *pytest*.

Em relação ao projeto de pesquisa, a visualização — inicialmente prevista em Leaflet.js puro — foi implementada por meio do Streamlit integrado ao Folium, biblioteca que encapsula o Leaflet, o que reduziu o esforço de integração entre o processamento em Python e a interface web.

5.3 DELIMITAÇÃO E COLETA DO CORPUS

A coleta foi delimitada a um corpus fechado e curado de notícias e boletins oficiais. Diferentemente do escopo inicialmente previsto — que contemplava coleta contínua em tempo real e captura de publicações na rede social X (Twitter) —, optou-se por um corpus fechado e verificado, por três razões metodológicas: (i) reprodutibilidade, pois um corpus fixo permite que a avaliação seja replicada com os mesmos dados; (ii) controle de qualidade, já que os textos foram verificados manualmente antes da inclusão; e (iii) viabilidade, dado que a coleta ao vivo depende da disponibilidade das URLs e da robustez do scraping, variáveis fora do escopo desta investigação.

A coleta na rede social X foi descartada como prioridade. Além das restrições de acesso à sua API e da instabilidade das bibliotecas de automação, a maioria das postagens não dispõe de geolocalização precisa, o que comprometeria o requisito central da pesquisa: a associação entre doença e município. Por isso, a investigação concentrou-se em fontes jornalísticas e boletins oficiais, nas quais a referência geográfica é explícita e rastreável.

O módulo de coleta de sementes parte de uma lista de URLs reais verificadas e tenta baixar o HTML original de cada matéria no momento da execução; quando o download não é possível — por exemplo, quando o domínio *cidadeverde.com* responde com bloqueio (HTTP 403, via Cloudflare) à coleta automatizada —, o sistema recorre a um texto de reserva previamente verificado e marca o registro como reserva utilizada. Esse desenho preserva a rastreabilidade e assegura a reprodutibilidade da avaliação. Um módulo de coleta ao vivo, configurado para quatro fontes (G1 Piauí, Cidade Verde, SESAPI e Meio News), foi implementado e mantido

no sistema, mas não constituiu a base da avaliação, justamente para garantir a estabilidade dos resultados.

O recorte temporal abrangeu o período de janeiro a dezembro de 2024, marcado pela alta incidência de arboviroses no estado. Foram selecionadas matérias que continham, no título ou na URL, ao menos uma das palavras-chave dengue, zika, chikungunya, arbovirose ou *Aedes*. O corpus final reuniu 35 artigos, distribuídos entre oito fontes, conforme a Tabela 1.

Tabela 1 – Composição do corpus por fonte

Fonte	Artigos
Cidade Verde	18
SESAPI	6
G1 Piauí	5
Ministério da Saúde	2
Governo do Piauí / SESAPI	1
Portal O Dia	1
Portal B1	1
A10+	1
Total	35

Fonte: Elaborada pelo autor (2025).

5.4 ESTRUTURAÇÃO E PERSISTÊNCIA DOS DADOS

A persistência foi implementada em um banco de dados relacional SQLite, escolhido por ser embutido, sem servidor e adequado ao escopo local da pesquisa. Em relação ao projeto inicial, que previa o armazenamento dos registros em arquivos JSON, adotou-se o SQLite como repositório principal — reservando-se o formato JSON ao armazenamento bruto das sementes e às exportações —, o que conferiu integridade referencial, deduplicação e consultas mais eficientes.

O banco organiza-se em duas tabelas. A tabela de notícias preserva o conteúdo bruto de cada matéria (fonte, título, texto, data de publicação, URL e metadados de coleta), garantindo a rastreabilidade até o documento original. A tabela de menções registra cada menção extraída pelo PLN, vinculada à respectiva notícia por chave estrangeira e contendo a doença, o município (com o código do IBGE), a sentença de origem, os sintomas identificados, o escore de confiança e o instante de extração.

Cada par (doença, município) identificado em uma sentença foi atomizado em um registro independente, de modo que uma única matéria que cite múltiplos municípios ou agravos gera múltiplas menções distintas. A duplicação foi evitada por uma restrição de unicidade sobre a combinação de notícia, doença, município e sentença, e a integridade entre menções e notícias foi assegurada por chave estrangeira com exclusão em cascata.

5.5 PIPELINE DE PLN E RECONHECIMENTO DE ENTIDADES (NER)

O núcleo analítico foi implementado com a biblioteca spaCy. O texto de cada notícia — composto pela concatenação de título e corpo — foi submetido à segmentação em sentenças e ao reconhecimento de entidades. O NER é a tarefa de extração de informação que localiza e classifica entidades em categorias predefinidas (Nadeau e Sekine, 2007). A identificação apoiou-se em um componente *EntityRuler*, configurado com correspondência sobre a forma em caixa baixa e com sobreposição às entidades do modelo base, o que privilegia regras explícitas e auditáveis em vez de predições probabilísticas opacas (Jurafsky e Martin, 2025).

Foram definidas três categorias de entidades: DOENÇA, MUNICÍPIO e SINTOMA. As doenças e suas variantes textuais constam do Quadro 1. Os municípios corresponderam à lista oficial dos 224 municípios do Piauí, obtida da base de localidades do IBGE, com correspondência tolerante à acentuação. Os sintomas compreenderam um conjunto de termos clínicos associados às arboviroses, como febre, dor de cabeça, dores articulares, manchas vermelhas e exantema.

Quadro 1 – Doenças monitoradas e variantes reconhecidas

Doença	Variantes reconhecidas
Dengue	dengue; dengue grave; dengue com sinais de alarme; arbovirose dengue
Zika	zika; vírus zika; zika vírus; febre do zika
Chikungunya	chikungunya; febre chikungunya; chikungunya vírus

Fonte: Elaborado pelo autor (2025).

5.6 HEURÍSTICA DE CO-OCORRÊNCIA E ATOMIZAÇÃO

Para converter entidades isoladas em informação útil à vigilância, aplicou-se uma heurística de co-ocorrência em escopo de sentença. A unidade de análise foi a sentença: somente quando uma entidade DOENÇA e uma entidade MUNICÍPIO

ocorrem na mesma sentença estabelece-se o vínculo, gerando uma menção. Quando uma sentença contém n doenças e m municípios, o sistema gera o produto cartesiano das $n \times m$ combinações; menções idênticas dentro de uma mesma notícia são descartadas. Essa regra é deliberadamente conservadora: privilegia a rastreabilidade e a precisão, ao custo de não capturar associações distribuídas por sentenças diferentes.

5.7 ESCORE DE CONFIANÇA

A cada menção atribuiu-se um escore de confiança operacional, calculado a partir de um valor-base de 0,62, acrescido de 0,18 quando há pelo menos um sintoma na sentença, de 0,08 adicionais quando há dois ou mais sintomas, e de 0,08 quando o título da notícia contém termo epidemiológico, limitado a um teto de 0,96. Trata-se de uma pontuação operacional destinada a ordenar e filtrar menções, e não de uma probabilidade epidemiológica. Como os textos de reserva raramente descrevem sintomas, a maioria das menções do corpus fechado situou-se em 0,70 (valor-base acrescido do bônus de título).

5.8 CONSTRUÇÃO DO PADRÃO-OURO (GOLD STANDARD)

Diante da inexistência de bases públicas anotadas para notícias de arboviroses no Piauí, construiu-se um conjunto de referência (Padrão-Ouro) por rotulagem manual. Em relação ao projeto inicial — que previa anotar uma amostra de 10% dos textos, ou no mínimo 50 documentos, no nível de entidade —, optou-se por anotar a totalidade dos 35 artigos do corpus e no nível de relação, isto é, tomando como unidade o par (doença, município) por artigo, sem duplicatas. Essa decisão alinhou a avaliação à pergunta de pesquisa, centrada na associação entre agravo e local, e ampliou o rigor ao cobrir todo o corpus.

A anotação resultou em 87 menções corretas. Os critérios formais adotados são apresentados no Quadro 2.

Quadro 2 – Critérios de anotação do Padrão-Ouro

Nº	Critério
1	Menção válida: arbovirose (Dengue, Zika ou Chikungunya) associada a município piauiense com presença confirmada ou suspeita — casos, óbitos, estado de alerta ou risco de infestação.
2	Menção negativa é inválida: artigo que informa explicitamente a ausência da

	doença no município não gera menção válida.
3	Referência geográfica é inválida: município citado apenas como referência espacial (ex.: distância) não gera menção válida.
4	Contexto de vacinação é válido: município associado a doença em contexto de vacinação conta como dado epidemiológico relevante.
5	Nível estadual é inválido: menções genéricas ao Piauí, sem município específico, não são contabilizadas.

Fonte: Elaborado pelo autor (2025).

5.9 PROCEDIMENTO DE AVALIAÇÃO

O desempenho do NER foi mensurado pela comparação entre as menções extraídas automaticamente e o Padrão-Ouro, tomando como chave a tripla (notícia, doença, município) deduplicada por artigo. A avaliação foi conduzida sobre os textos de reserva do corpus fechado, assegurando reprodutibilidade. A partir da matriz de confusão, calcularam-se três métricas consagradas na literatura de Recuperação da Informação. A Precisão (precision) mede, entre as menções extraídas, a proporção de corretas, penalizando os falsos positivos. A Revocação (recall) mede, entre as menções de fato existentes, a proporção recuperada, penalizando os falsos negativos. O F1-score é a média harmônica entre precisão e revocação, oferecendo uma medida equilibrada do desempenho. As métricas foram calculadas de forma agregada e por doença.

5.10 ASPECTOS ÉTICOS

A pesquisa utilizou exclusivamente dados públicos e secundários, sem participantes humanos e sem dados sensíveis, o que dispensa a submissão ao Comitê de Ética em Pesquisa. A coleta automatizada observou as diretrizes de ética na web, incluindo a verificação do arquivo robots.txt dos portais e o respeito às restrições de acesso, e o tratamento dos dados observou a Lei Geral de Proteção de Dados (LGPD).

6 RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos com a execução do protótipo sobre o corpus fechado de 2024 e discute seus significados e limitações. São reportados a composição do corpus, o Padrão-Ouro construído, o desempenho do NER, a análise dos erros, o comportamento da visualização e, por fim, a discussão integrada à luz da pergunta de pesquisa.

6.1 COMPOSIÇÃO DO CORPUS

O corpus reuniu 35 artigos publicados ao longo dos doze meses de 2024, cobrindo o ciclo epidêmico da dengue no estado — crescimento no primeiro trimestre, pico em torno de março e abril e posterior redução — além da vigilância de chikungunya no segundo semestre. A distribuição por fonte (Tabela 1) evidencia a predominância do portal Cidade Verde, com 18 dos 35 artigos, seguido dos boletins da SESAPI (6) e do G1 Piauí (5); as demais fontes contribuíram com um a dois artigos cada.

6.2 PADRÃO-OURO CONSTRUÍDO

A anotação manual identificou 87 menções válidas. Desse total, 22 dos 35 artigos continham ao menos uma menção, enquanto 13 não apresentaram menção válida segundo os critérios definidos. A distribuição por doença (Tabela 2) revelou forte predominância da dengue, com 83 menções, seguida da chikungunya, com 4, e ausência de menções de zika associadas a município específico — a zika apareceu no corpus apenas em nível estadual, sem vínculo municipal.

Tabela 2 – Distribuição do Padrão-Ouro por doença

Doença	Menções
Dengue	83
Chikungunya	4
Zika	0
Total	87

Fonte: Elaborada pelo autor (2025).

6.3 DESEMPENHO DO RECONHECIMENTO DE ENTIDADES

O pipeline extraiu, após deduplicação por artigo, 39 pares (doença, município), dos quais 37 corretos e 2 incorretos, deixando de recuperar 50 menções presentes no Padrão-Ouro. O desempenho agregado e por doença é apresentado na Tabela 3.

Tabela 3 – Desempenho do NER por doença e agregado

Entidade	VP	FP	FN	Precisão	Revocação	F1
Dengue	33	2	50	94,3%	39,8%	55,9%
Chikungunya	4	0	0	100,0%	100,0%	100,0%
Zika	0	0	0	—	—	—
Geral	37	2	50	94,9%	42,5%	58,7%

Fonte: Elaborada pelo autor (2025). Legenda: VP = verdadeiros positivos; FP = falsos positivos; FN = falsos negativos.

Os resultados revelam um sistema de alta precisão (94,9%) e revocação moderada (42,5%), sintetizadas por um F1-score de 58,7%. A elevada precisão indica que, quando o sistema extrai uma menção, quase sempre acerta — comportamento coerente com a regra conservadora de co-ocorrência sentencial. O resultado perfeito da chikungunya (F1 = 100%) deve ser lido com cautela, pois se baseia em apenas quatro instâncias, base amostral insuficiente para generalização. Para a zika, não havendo menções municipais no corpus, não foi possível mensurar o desempenho.

6.4 ANÁLISE DE ERROS

Os dois falsos positivos têm causas distintas e ilustram limitações conhecidas de sistemas baseados em regras, sintetizadas no Quadro 3. No primeiro caso, o sistema extraiu a co-ocorrência em uma sentença que negava a ocorrência da doença, pois não há tratamento de negação. No segundo, o município de Teresina foi citado apenas como referência espacial, e o sistema não distingue contexto de ocorrência de contexto de referência geográfica.

Quadro 3 – Falsos positivos e suas causas

Menção extraída	Causa do erro
(Dengue, Picos)	Negação não detectada — a sentença afirmava que Picos ainda não havia registrado casos de dengue em 2024.
(Dengue, Teresina)	Referência geográfica — Teresina foi citada como distância de referência (a cerca de 600 km de um óbito ocorrido em Bom Jesus), e não como local de ocorrência.

Fonte: Elaborado pelo autor (2025).

Os 50 falsos negativos têm causa quase exclusivamente estrutural: artigos que mencionam a doença em uma sentença e listam os municípios afetados em outra — padrão típico de notas de imprensa e boletins epidemiológicos. Como a heurística exige co-ocorrência na mesma sentença, essas associações não são capturadas. Exemplos recorrentes envolvem boletins que afirmam o aumento da dengue no estado em uma sentença e, na seguinte, enumeram os municípios com casos ou óbitos confirmados.

6.5 VISUALIZAÇÃO E PADRÃO TEMPORAL

Em operação normal — com tentativa de download e recurso ao texto de reserva quando necessário —, o sistema consolidou 49 menções no banco, sendo 46 de dengue e 3 de chikungunya, ante 47 obtidas estritamente sobre os textos de reserva; a pequena diferença decorre de uma ou duas matérias efetivamente baixadas com conteúdo mais extenso. O painel reproduziu corretamente o padrão sazonal da dengue em 2024 — crescimento de janeiro a março, pico em torno de março e abril e queda posterior —, com a chikungunya em menor intensidade e pico deslocado para o segundo semestre, comportamento coerente com os dados epidemiológicos reais do estado.

Ressalta-se que as métricas de precisão, revocação e F1 foram calculadas sobre o corpus de textos de reserva, ao passo que as 49 menções refletem o modo operacional do sistema (download com contingência); por isso, esses números não são diretamente comparáveis.

6.6 DISCUSSÃO

Os resultados respondem à pergunta de pesquisa de forma matizada: é viável identificar e geolocalizar automaticamente menções a arboviroses em notícias do Piauí com alta precisão, mas a cobertura é limitada quando se adota uma heurística de co-ocorrência estritamente sentencial. Em termos práticos, o protótipo é mais útil como filtro de alta precisão — que minimiza falsos alarmes — do que como mecanismo de cobertura exaustiva. Esse achado atende ao objetivo específico de avaliar a precisão da aplicação na identificação de doenças e localidades.

As principais limitações identificadas foram: (i) a heurística de co-ocorrência sentencial, responsável por praticamente todos os falsos negativos; (ii) a ausência de

tratamento de negação; (iii) a ambiguidade de referência geográfica; (iv) a impossibilidade de avaliar a zika, ausente em nível municipal no corpus; (v) o viés de cobertura das fontes, com predominância de um único portal; e (vi) o acoplamento do sistema ao recorte do Piauí e às três arboviroses, definido por listas fixas no código. Tais limitações delimitam o alcance das conclusões e apontam caminhos de aprimoramento, como o tratamento de negação, a expansão da janela de associação para além da sentença e a incorporação de classificação supervisionada para reduzir falsos positivos.

Por fim, reitera-se o caráter de prova de conceito do artefato: os resultados demonstram a viabilidade técnica da abordagem com ferramentas de baixo custo e código aberto, sem a pretensão de substituir os sistemas oficiais de vigilância ou de servir como fonte única para decisões em saúde pública.